

基于卡尔曼滤波的导航系统的故障检测^{*}

宋 健 王 磊

(同济大学中德学院,上海 200000)

摘 要:探讨了一种导航系统的故障检测方法,即基于卡尔曼滤波的残差²检验.在传统方法和现代方法对比层面上对该方法进行了分析,然后又通过一个具体实例进一步讨论了如何利用神经网络的优点来提高该方法的检测效果.

关键词:残差²检验;卡尔曼滤波;神经网络

中图分类号:V241 **文献标识码:**A **文章编号:**1008-4681(2005)05-0004-04

Failure Detection in the Navigation System Based on Kalman Filtering Tongji University

SONG Jian WANG Lei

(College of Zhongle, Tongji University, Shanghai 200000)

Abstract: In this paper a failure detection method in the Navigation System is introduced, which is residual chi-square test based on kalman filtering. Through the analyse to the method, we have discussed how to improve detected effect with the application of neural networks.

Key words: residual chi-square test; failure detection; neural networks

1 问题的提出

随着科学技术的发展以及人们探索自然步伐的加大,系统的自动化水平越来越高,复杂性也越来越大,因此可靠性显得至关重要.对于导航系统来说,可靠性显得尤为突出.一旦导航系统出现故障,就有可能造成灾难性的后果.于是能及时发现导航系统中的故障并加以定位正是人们目前要研究的导航系统故障检测问题.

2 当前研究状况

在飞行控制系统这个领域,美国走在了前面.早在 70 年代,美国麻省理工学院 Beard 的博士论文中就提到用解析冗余代替硬件冗余并通过系统自组织使系统稳定,通过比较观测器的输出得到系统故障信息.这标志着以软件为主导的故障检测和隔离(FDI)技术首先在美国发展起来了.故障检测与隔离飞控系统故障研究主要理论基础是:Richard V. Beard 于 1971 年提出的检测滤波器法(该方法通过设计对特定故障敏感的状态观测器,从而突出特定故障信息);Edward Y. Chow 于 1986 年提出的扩展等价空间法(该方法利用系统动态方

程中的线性相关性获得故障信息).目前还有一些人研究系统参数辨识,卡尔曼滤波器,多模型匹配,马氏链故障检测方法.这些方法中观测器法和卡尔曼滤波器法的抗干扰能力强,等价空间法算法简洁且无发散性问题.除了这些常规数据处理的故障检测方法,基于知识的人工智能故障检测方案也逐渐成熟,人工智能可用于故障信号的提取,故障分类以及检测参数调节.采用专家系统,模糊推理,人工神经网络等基于经验或自学习的方案,可归纳为采用规则的浅知识和来自模型推理的深层知识.采用推理模型的深层知识,可适应位置故障和环境变化的飞控系统.

本文主要介绍其中比较典型的卡尔曼滤波器法,进而又讨论了利用神经网络对上述检测方法的改进和补充.首先简单介绍我们要用到的以下基本知识.

3 基本原理

卡尔曼滤波

卡尔曼滤波是具有递推形式的先行最小方差估计,他从与被提取信号有关量的测量中,通过算法估计出所需信号.条件是被估计的信号是由白噪声驱动而产生的随机信号,激励源与响应之间的传

^{*} 收稿日期:2005-01-06

作者简介:宋 健(1979-),男,江西南昌人,同济大学在读硕士,主要从事测量和检测的研究.

指导老师:王 磊(1961-),男,陕西西安人,同济大学教授,主要从事智能控制,测量和检测研究.

递结构(系统方程)已知,量测量与被估计量之间的函数关系(量测方程)也已知.其特点为:

1、处理信号是随机信号;

2、被处理信号不分是有用信号和干扰信号,滤波的目的是要估计出所有被处理信号;

3、系统的白噪声激励和两侧噪声并不是需要滤除的对象,他们的统计特性正是估计过程中需要利用的信息;

4、由于采用了状态空间法描述系统,算法采用递推方式,故该方法可以处理多为何非平稳过程.

卡尔曼滤波基本方程:

设 t_k 时刻的被估计状态 X_k 受系统噪声序列 W_k 驱动,动力学关系由下述状态方程描述:

$$X_k = \Phi_{k,k-1} X_{k-1} + \Gamma_{k-1} W_{k-1} \quad (1)$$

对 X_k 的量测满足线性关系,量测方程为:

$$Z_k = H_k X_k + V_k \quad (2)$$

式中, $\Phi_{k,k-1}$ 为 t_{k-1} 时刻至 t_k 时刻的一步转移阵,为系统噪声驱动阵, H_k 为量测阵, V_k 为量测噪声序列, W_k 和 V_k 都是随机向量,满足:

$$\begin{cases} E[W_k] = 0, \text{Cov}[W_k, W_j] = E[W_k W_j^T] = Q_k \delta_{kj} \\ E[V_k] = 0, \text{Cov}[V_k, V_j] = E[V_k V_j^T] = R_k \delta_{kj} \\ \text{Cov}[W_k, V_j] = E[W_k V_j^T] = 0 \end{cases} \quad (3)$$

其中, δ_{kj} 为狄拉克(Dirac)函数, Q_k 和 R_k 分别为白噪声的普密度矩阵. Q_k 为系统噪声序列的方差阵,假设为非负定阵; R_k 为量测噪声序列的方差阵,假设为正定阵.

则 X_k 的线性最小方差估计 \hat{X}_k 按下述递推方程求解:

状态一步预测:

$$\hat{X}_{k/k-1} = \Phi_{k,k-1} \hat{X}_{k-1} \quad (4)$$

状态估计:

$$\hat{X}_k = \hat{X}_{k/k-1} + K_k (Z_k - H_k \hat{X}_{k/k-1}) \quad (5)$$

滤波增益阵:

$$K_k = P_{k/k-1} H_k^T (H_k P_{k/k-1} H_k^T + R_k)^{-1} \quad (6)$$

一步预测均方误差阵:

$$P_{k/k-1} = \Phi_{k,k-1} P_{k-1} \Phi_{k,k-1}^T + \Gamma_{k-1} Q_{k-1} \Gamma_{k-1}^T \quad (7)$$

估计均方误差阵:

$$P_k = (I - K_k H_k) P_{k/k-1} (I - K_k H_k)^T + K_k P_k K_k^T \quad (8)$$

残差阵: $\hat{X}_k = Z_k - H_k \hat{X}_{k/k-1} \quad (9)$

上述即为离散型卡尔曼滤波基本方程.只要给定初值 X_0 和 P_0 ,根据 K 时刻的量测 Z_k ,就可以递推计算出 K 时刻的状态估计 $\hat{X}_k (K=1, 2, \dots)$.

卡尔曼滤波分为两个更新过程:

1、时间更新

式(4):根据 $k-1$ 时刻的状态估计预测 k 时刻

的状态;

式(5):定量评价上面预测的质量;

上述计算只用到了与系统动态特性有关的信息,如一步转移阵、噪声驱动阵、驱动噪声的方差阵.在时间上,将时间 $k-1$ 推向 k 时刻.

2、量测更新

其余各式用于计算时间更新值得修正量,该修正量由由时间更新质量优劣、量测信息质量优劣、量测的预测和真实量测值的残差确定.

残差²检验

式中的 $\hat{X}_{k/k-1}$ 就是测量值 Z_k 减去预测值 $\hat{X}_{k/k-1}$ 所得的残差:

$$Z_{k/k-1} = Z_k - \hat{X}_{k/k-1} = H_k X_k + V_k -$$

$$H_k \hat{X}_{k/k-1} = H_k \hat{X}_{k/k-1} + V_k$$

无故障时系统应该满足状态方程式,因此 $\hat{X}_{k/k-1}$ 是 X_k 的无偏估计,所以 $Z_{k/k-1}$ (即 $\hat{X}_{k/k-1}$) 是零均值的高斯白噪声向量;当传感器发生故障,那么系统就不再满足状态方程式,因此 $\hat{X}_{k/k-1}$ 的均值不再为零(假设此时仍然服从正态分布).故对 $\hat{X}_{k/k-1}$ 的均值作假设检验可判决传感器是否有故障.

神经网络

神经网络从拓扑结构上可以看成是以处理单元为节点,用加权有向弧连接而成的有向图.其中处理单元是对生物神经元的模拟,而有向弧则是对轴突-树突对的模拟.有向弧的权值,即连接权值,标志着两处理单元之间相互影响的强弱.全部有向弧的权值构成连接权矩阵.神经网络的信息存储于连接权矩阵中,因此是分布式存储,且存储区和操作区合为一体,这使得神经网络具有较大的信息冗余和容错能力.神经网络是由大量功能简单的处理单元(神经元)广泛连接形成的网络,是对生物脑神经系统非常简单的模拟.虽然每个神经元的结构功能简单,但是由大量神经元构成的网络,其行为是丰富多彩和复杂的,是高度复杂的非线性动力学系统,具有连续时间动力学和网络全局作用的特点,具有大规模并行模拟处理的能力,已经成功的应用到许多不同的领域.

现在已经提出了各种具备不同信息处理能力的神经网络模型及学习算法.其中具有代表性的神经网络模型有感知器、多层 BP 网络、对传网络(Counterpropagation Network)、径向基函数(RBF)网络、回归网络、双向联想记忆(BAM)网络、Hopfield 网络等.典型的学习算法有误差反向传播算法、遗传算法、模拟退火算法、关联学习算法等等.

在各种神经网络中,多层前传 BP 网络是应用最广泛的一种.在我们接下来的实例中我们将用到

的就是一个三层的 BP 网络. 有关 BP 网络的知识可参考文献[10].

由于我们基于模型的残差产生算法一般都建立在对被检测系统数学模型的低阶近似描述上. 这种模型的低阶近似和残差值的先行计算方法, 使得残差信号中不可避免的存在着模型偏差. 为了能够抑制无故障残差信号中的模型偏差, 我们考虑引入人工神经网络. 因为神经网络不仅可以离线而且可以在线学习, 从而可以获得更精确的系统或故障模型. 因此, 在基于上述残差²检验, 我们再利用神经网络来训练动态系统的非线性模型, 构成第二个观测

器. 预测系统的输出, 再由神经网络观测器和实际的系统输出产生残差, 通过检验残差来检测故障.

4 仿真实例

本例采用捷联惯导系统, 以东北天地理坐标系为导航坐标系 (n 系), 用下标 E, N, U 表示东、北、天方向. 机体系 b 系用下标 x, y, z 表示, 右机翼方向为 x, 机头方向为 y, 天向为 z. 陀螺仪, 加速度计, GPS 接收机的误差模型及其量值见下表. 假定传感器的每个轴具有相同的误差模型.

表 1 GPS 接收机的误差模型及其量值表

传感器	误差模型	统计特性	坐标系
陀螺仪	陀螺仪误差 w_g 由一阶 Markov 过程和白噪声 w_g 构成	$E[w_g] = 0$ $E[w_g w_g^T] = (0.01)^2 (\tau_g h)$ $E[w_g] = 0$	b 系 (x, y, z)
	$\dot{w}_g = -\frac{1}{\tau_g} w_g + w_g$	$E[w_g w_g^T] = \frac{2}{3} (\tau_g h)^2 / h$ $\tau_g = 3 (h)$	
	其中 τ_g 为一阶 Markov 过程的相关时间, w_g 为激励 Markov 过程的白噪声		
加速度计	加速度计误差 w_a 由常值偏差 ∇ 和白噪声 w_a 构成	$\nabla = 0.1 (mg)$ $E[w_a] = 0$	b 系 (x, y, z)
	$\nabla_a = \nabla + w_a$	$E[w_a w_a^T] = (50 \mu g)^2 sec$	
GPS 接收机	GPS 接收机误差 w_g 由一阶 Markov 过程和白噪声 v 构成	$E[v] = 0$ $E[v v^T] = 1.0 (m)$ $E[w_g] = 0$	n 系 (E, N, U)
	$\dot{w}_g = -\frac{1}{\tau_g} w_g + v$	$E[w_g w_g^T] = 0.833 (m^2 / sec)$ $\tau_g = 60.0 (sec)$	
	其中 τ_g 为一阶 Markov 过程的相关时间, w_g 为激励 Markov 过程的白噪声		

我们取位置误差 r_E, r_N, r_U , 速度误差 v_E, v_N, v_U , 平台误差角 $\epsilon_E, \epsilon_N, \epsilon_U$, 加速度计偏差 $\nabla_x, \nabla_y, \nabla_z$, 陀螺仪 Markov 误差分量 w_x, w_y, w_z , GPS 接收机 Markov 误差分量 w_E, w_N, w_U , 为 INS/GPS 组合导航系统的误差状态变量, 即为我们的方程状态变量.

$$X^T = [r_E \ r_N \ r_U \ v_E \ v_N \ v_U \ \epsilon_E \ \epsilon_N \ \epsilon_U \ \nabla_x \ \nabla_y \ \nabla_z \ w_x \ w_y \ w_z \ w_E \ w_N \ w_U]$$

INS/GPS 组合导航系统只利用 GPS 的三位置信息组合, 即惯导系统给出的经纬度、高度信息和 GPS 接收机给出的相应信息的差值为一组测量值.

表示惯导系统的位置信息为

$$l = l_t + \frac{r_E}{R \cos \theta}$$

$$l = l_t + \frac{r_N}{R}$$

$$h_l = h_t + r_U$$

表示 GPS 接收机给出的位置信息为

$$G = l_t + \frac{r_E}{R \cos \theta} + \frac{r_N}{R \cos \theta}$$

$$G = l_t + \frac{r_N}{R} + \frac{r_U}{R}$$

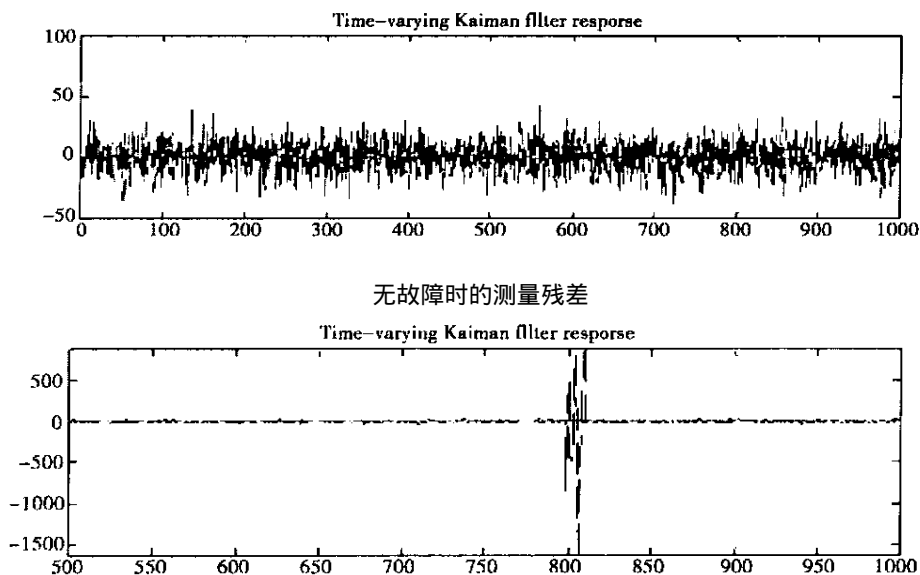
$$h_G = h_t + r_U + v_U$$

式中, r, r, h_r 为真实位置; v_E, v_N, v_U 表示 GPS 接收机沿东、北、天方向测量的白噪声项. 我们定义量测矢量为:

$$z(t) = \begin{bmatrix} (l_t - G) R \cos \theta \\ (l_t - G) R \\ h_t - h_G \end{bmatrix} = H(t) x(t) + v(t)$$

假设导航信息的初始误差为: 位置误差 100m, 速度误差 1.0m/s, 水平姿态误差角 300", 方位误差角 900". 飞行航线包括加速、减速、平飞等飞行姿态, 初始航向角为 35", 平飞速度为 300m/s. 惯导系统采用输出校正, 滤波周期为 1 秒, 仿真时间为 1000s. 基于卡尔曼滤波的残差²检验所得的仿真


结果如图:



引入故障后的测量残差图

由上图我们可以看到,系统在 800 秒时引入了误差,通过基于卡尔曼滤波原理的残差 2 检验,当发现故障是将故障源取消,我们可以在 818 秒时发现故障并排除。

接下来我们要在上述方法的基础上,再添加一个基于 BP 神经网络的状态观测器,通过神经网络的在线学习后,将其应用于对系统模型误差的校正,可以起到很好的效果。仿真结果如下图:



BP 神经网络辅助下的测量残差图

很明显,实验结果表明当同样在 800 秒时引入故障,现在系统能够在 806 秒就发现故障并排除,大大缩短了时间。由此可见,引入神经网络提高了系统故障检测能力。

5 小 结

传统的基于卡尔曼滤波原理的残差²检验对模型失配的鲁棒性很差,因此当系统中出现故障时,残差会迅速增大,所以该方法具有检测速度快的特点。但是另一方面模型的失配也会造成残差的增大,因此误报率比较高。为此,我们引入了神经网络很好的弥补了这点。这种方法非常适用于突变性故障的检测,为了减少误报率,可以适当提高阈值的大小,以提高算法的抗干扰能力。

参考文献:

- [1] 徐力平. 组合导航系统故障检测技术的研究[M]. 上海: 上海交通大学, 2001.
- [2] 周东华, 孙优贤, 等. 控制系统的故障检测与隔离技术[M]. 北京: 清华大学出版社, 1994.
- [3] 王华. Matlab 在电信工程中的应用[M]. 北京: 中国水利水电出版社, 2001.
- [4] 何迎晖. 随机过程简明教程[M]. 上海: 同济大学出版社, 2000.
- [5] 任立明. 水下自航器传感器故障的检测与隔离[J]. 西北工大学报, 1998, (10): 75 - 77.
- [6] 闻新. MATLAB 神经网络应用[M]. 北京: 科学出版社, 2001.
- [7] 邓建国. 基于 BP 神经网络的电机系统的波形控制[M]. 长沙: 湖南大学, 2000.
- [8] 胡德文. 多层神经网络逼近精度研究[M]. 首届中国神经网络学术大会论文集, 1990.
- [9] Simon Haykin. Neural Networks[M]. China Machine Press 2004.